

Tarea 3: Mapas

Tema: Large Language Models (LLMs)

Isaías Carte Figueroa Nicolás Gonzáles Benjamín Olguín Pozo

Visualización de Datos – Semestre I 2026
Universidad Técnica Federico Santa María

1. Introducción

Esta entrega continúa el análisis desarrollado en las tareas anteriores sobre Large Language Models (LLMs). En esta etapa, el foco se traslada hacia la dimensión espacial del fenómeno, utilizando mapas para observar dónde se concentran los modelos, cómo varía la apertura de estos modelos según el país y qué infraestructura física sostiene su entrenamiento y operación.

El trabajo integra tres mapas distintos, elaborados con herramientas y enfoques diferentes: un mapa coroplético mundial, un mapa de símbolos proporcionales con codificación de color y un mapa de puntos sobre infraestructura de cómputo. En conjunto, estas visualizaciones permiten analizar el ecosistema global de los LLMs desde una perspectiva geográfica, tecnológica e infraestructural.

2. Desarrollo individual

2.1. Isaías Carte – Concentración geográfica de modelos LLM notables

Visualización: <https://public.flourish.studio/visualisation/29355748/>

Fuente de datos: Epoch AI – *Notable AI Models*. Disponible en: <https://epoch.ai/data/ai-models?view=table&tab=notable>

Descripción cualitativa del dataset

El dataset utilizado corresponde a la base *Notable AI Models* de Epoch AI, filtrada para considerar modelos asociados al dominio de lenguaje. Esta base reúne modelos relevantes dentro del desarrollo de la inteligencia artificial e incluye información como nombre del modelo, organización desarrolladora, fecha de publicación, dominio y país asociado a la organización.

Para esta visualización se consideraron modelos LLM publicados entre 2018 y 2025. A partir del dataset original, los registros fueron agrupados por país de la organización desarrolladora, calculando la cantidad total de modelos LLM notables por territorio. Además, se adaptaron los nombres de países al formato utilizado por Flourish y se incorporaron países con valor cero para que el mapa mundial se visualizara completo.

El dataset permite observar la distribución territorial del desarrollo de LLMs notables. Sin embargo, debe interpretarse como una aproximación, ya que el país corresponde a la organización asociada al modelo y no necesariamente al lugar exacto donde se realizó todo el desarrollo, investigación o entrenamiento.

Tipo de mapa

La visualización corresponde a un **mapa coroplético mundial** realizado en Flourish. Cada país se colorea según la cantidad de modelos LLM notables asociados a organizaciones de ese territorio. Se utilizó una escala secuencial por cuartiles para reducir el efecto de valores extremos, especialmente Estados Unidos y China, y permitir que también sean visibles países con menor cantidad de registros.

Objetivo de la visualización

La pregunta principal que busca responder es: **¿en qué países se concentra el desarrollo de modelos LLM notables entre 2018 y 2025?**

De forma secundaria, el mapa permite observar qué regiones tienen baja o nula presencia en el desarrollo de estos modelos y qué tan concentrado está geográficamente el ecosistema global de los LLMs.

La visualización está dirigida a estudiantes, docentes y personas interesadas en inteligencia artificial, especialmente a quienes buscan comprender el desarrollo de los LLMs desde una perspectiva global y no solo técnica.

El mapa puede apoyar discusiones sobre concentración tecnológica, desigualdad geográfica en el desarrollo de inteligencia artificial y dependencia de ciertos países líderes en el ecosistema LLM. También puede servir como apoyo para análisis académicos, decisiones de investigación, colaboración internacional o identificación de regiones subrepresentadas en el desarrollo de modelos avanzados.



Source: Fuente: Epoch AI – Notable AI Models. Elaboración propia a partir de modelos de lenguaje publicados entre 2018 y 2025.

Figura 1: Mapa coroplético de concentración geográfica de modelos LLM notables.

Conclusión principal

El mapa evidencia que el desarrollo de modelos LLM notables se encuentra altamente concentrado en pocos países. Estados Unidos y China destacan como los principales focos de desarrollo, mientras que gran parte de América Latina, África y otras regiones presentan baja o nula presencia en el dataset. Esto sugiere que el avance de los LLMs no se distribuye de manera homogénea a nivel global.

2.2. Benjamín Olguín – Proporción de acceso abierto en modelos LLM por país

Fuente de datos: Epoch AI – *Notable AI Models*. Disponible en: <https://epoch.ai/data/ai-models?view=table&tab=notable>. Descarga directa: https://epoch.ai/data/notable_ai_models.csv

Criterios seleccionados

Los criterios utilizados fueron: (1) país de origen de la organización desarrolladora, (2) proporción de modelos con pesos abiertos por país y (3) cantidad total de modelos LLM por país. Estos criterios permiten analizar simultáneamente la productividad de cada país y el grado de apertura de su ecosistema de modelos.

Justificación de los criterios

Estos criterios permiten analizar dos dimensiones del ecosistema global de LLMs: la **productividad**, entendida como la cantidad de modelos publicados por país, y la **apertura**, entendida como la proporción de modelos cuyos pesos fueron publicados abiertamente. La combinación de ambas variables permite detectar patrones geográficos que no serían visibles si solo se observara la cantidad total de modelos.

La elección de un mapa de símbolos proporcionales con codificación de color se justifica porque el tamaño del símbolo comunica la cantidad total de modelos, mientras que el color muestra el porcentaje de acceso abierto. Así, el mapa permite comparar países con alta producción, pero también distinguir si esa producción se orienta hacia modelos más abiertos o más cerrados.

Descripción cualitativa del dataset

El dataset de Epoch AI registra modelos de inteligencia artificial considerados notables según criterios técnicos y de impacto. Para cada modelo se incluyen, entre otros campos, la fecha de publicación, la organización desarrolladora, el país de origen de la organización, el dominio y la columna `Open model weights?`, que indica si los pesos del modelo fueron publicados abiertamente.

Para esta visualización se aplicaron los siguientes filtros: únicamente modelos cuyo dominio incluye lenguaje, publicaciones entre 2018 y 2025 y exclusión de registros sin dato en `Open model weights?`. Luego, los modelos se agruparon por país de origen, calculando el total y el número de modelos abiertos para obtener el porcentaje de apertura por nación.

El dataset es de acceso público y es actualizado por Epoch AI, lo que le otorga confiabilidad y trazabilidad. No obstante, debe interpretarse como una aproximación al ecosistema de acceso abierto, ya que la apertura se evalúa a nivel de publicación de pesos y no necesariamente de licencias, datasets o código asociado.

Tipo de mapa

La visualización corresponde a un **mapa de símbolos proporcionales con codificación de color**, desarrollado en Python con Plotly Express. La posición geográfica representa el país, el tamaño del círculo codifica la cantidad total de modelos LLM notables y el color indica el porcentaje de modelos con pesos abiertos.

Este tipo de mapa se diferencia del coroplético porque no depende del tamaño geográfico de los países, y se diferencia del mapa de puntos porque no representa registros individuales, sino valores agregados por país. En este caso, la codificación doble permite mostrar tanto volumen de producción como proporción de apertura.

Objetivo de la visualización

La pregunta principal que busca responder es: **¿qué países producen más modelos LLM y qué tan abiertos son?**

Como pregunta secundaria, el mapa permite observar si existe una relación entre la geopolítica de la IA y la proporción de modelos de acceso abierto.

La visualización está dirigida a investigadores en IA, responsables de políticas tecnológicas, organizaciones interesadas en estándares abiertos y empresas que evalúan estrategias de adopción de LLMs según su accesibilidad.

El mapa puede apoyar decisiones de colaboración internacional, análisis sobre apertura del ecosistema y discusiones sobre soberanía tecnológica y disponibilidad de modelos reutilizables.




Figura 2: Mapa de símbolos proporcionales sobre modelos LLM por país y proporción de acceso abierto.

Resultados principales

En el período 2018–2025 se consideraron 407 modelos LLM notables con información sobre acceso abierto. Estados Unidos concentra 252 modelos, de los cuales 98 son abiertos (38,9 %). China registra 101 modelos, con 57 abiertos (56,4 %). También destacan Corea del Sur (54,5 %), Francia (57,1 %), Canadá (60,0 %), Israel (66,7 %) y casos puntuales como Emiratos Árabes Unidos, Japón y Suiza con 100 % de apertura, aunque con pocos modelos.

Conclusión principal

El mapa revela un patrón doble que no es visible al analizar solo la cantidad de modelos por país. Estados Unidos y China dominan cuantitativamente la producción de LLMs, pero presentan estrategias de apertura distintas: Estados Unidos lidera ampliamente, aunque con una proporción relativamente baja de modelos abiertos, mientras que China combina alta producción con una apertura mayor. Además, el Reino Unido aparece como un caso llamativo de

producción relevante pero completamente cerrada dentro del período analizado. En conjunto, la visualización sugiere que el liderazgo en LLMs no solo depende de cuántos modelos se producen, sino también de qué tan abiertos son para su reutilización y análisis.

2.3. Nicolás Gonzáles – Infraestructura física de cómputo para IA

Visualización: <https://datawrapper.dwcdn.net/fl7nJ/1/>

Descripción cualitativa del dataset

El dataset reúne los principales centros de datos y superclusters de GPUs/TPUs asociados al entrenamiento y operación de modelos de IA a nivel mundial. Fue construido a partir de fuentes especializadas en infraestructura de cómputo, reportes de prensa, análisis sectoriales y comunicados de proyectos.

Cada registro corresponde a un campus e incluye información como operador, ciudad o zona, país, región, coordenadas geográficas, capacidad eléctrica en MW, estado del proyecto, uso principal y un indicador de confiabilidad del dato.

El dataset debe interpretarse considerando algunas limitaciones. Primero, existe una asimetría de transparencia entre regiones, especialmente porque algunos países reportan capacidad de cómputo de forma distinta o menos detallada. Segundo, varios campus se construyen por fases, por lo que la capacidad puede representar valores proyectados. Tercero, algunos centros de datos son de uso mixto y no exclusivamente de entrenamiento de LLMs.

Tipo de mapa

La visualización corresponde a un **mapa de puntos** realizado en Datawrapper. Cada punto representa un centro de datos o campus de cómputo. El tamaño del punto codifica la capacidad eléctrica del campus en MW y el color identifica al operador.

Se eligió un mapa de puntos porque el fenómeno relevante ocurre a nivel de campus individual y no solamente a nivel de país. Esto permite mostrar concentraciones internas dentro de un mismo territorio, como los clústeres de infraestructura en Estados Unidos.

Objetivo de la visualización

La pregunta principal que busca responder es: **¿dónde se encuentra la infraestructura física que entrena y opera los LLMs, quién la controla y a qué escala energética?**

De forma secundaria, permite distinguir qué parte de esa infraestructura ya está operativa frente a la que aún se encuentra en construcción, además de observar el grado de concentración geográfica y de operadores.

La visualización está dirigida a estudiantes y personas interesadas en inteligencia artificial, así como a analistas de infraestructura y energía, planificadores territoriales y tomadores de decisión en política pública.


El mapa puede apoyar discusiones sobre el impacto energético y territorial de la IA, soberanía tecnológica, dependencia de pocas regiones y presión sobre redes eléctricas y recursos hídricos.

¿Dónde se entrena la IA?

Tamaño = capacidad eléctrica (200–2.000 MW); color = operador.

Alibaba Cloud Amazon (para Anthropic) Google MGX / Mistral / Nvidia Meta Microsoft
Nebius Nscale / Aker / OpenAI OpenAI / G42 / MGX OpenAI / Oracle Tencent xAI

capacidad_mw ○ 200 ○ 800 ○ 2,000



Map: Nicolás González • Source: Epoch AI, AI Data Center Index, m-ric, TechCrunch, Sherwood News, Neowin, Rystad Energy, Blackridge Research. • Created with Datawrapper

Figura 3: Mapa de puntos sobre infraestructura física de cómputo para IA.

Fuentes de datos

Las fuentes utilizadas para construir el dataset de infraestructura son:

- Epoch AI – Frontier Data Centers / Stargate: <https://epoch.ai/blog/openai-stargate-where-they-are-building>
- AI Data Center Index: <https://aidatacenterindex.com>
- m-ric – The 3 tiers of the AI compute race: <https://m-ric.com/blog/datacenter-buildout/>
- TechCrunch – Meta Prometheus y Hyperion: <https://techcrunch.com/2025/07/14/mark-zuckerberg-says-meta-is-building-a-5gw-ai-data-center>
- Sherwood News – xAI Colossus: <https://sherwood.news/tech/clash-of-the-titans-here-are-the-ai-data-centers>

- Neowin – Microsoft Fairwater y Amazon Project Rainier: <https://www.neowin.net/news/these-are-the-biggest-ai-data-centers-owned-by-big-tech/>
- Rystad Energy – contexto de China: <https://www.rystadenergy.com/news/chinas-data-center->
- Blackridge Research – Stargate UAE: <https://www.blackridgeresearch.com/blog/facts-you-need-to-know-about-openai-stargate-ai-data-center-project-abilene-texas->

Conclusión principal

El mapa evidencia que la infraestructura física que sostiene a los LLMs está fuertemente concentrada. Estados Unidos reúne una parte importante de los campus mapeados y algunos de los proyectos de mayor escala individual. Europa aparece con proyectos reales, pero de menor magnitud, mientras que China solo puede observarse parcialmente debido a la menor transparencia de los datos. Además, la capacidad de cómputo se concentra en un grupo reducido de operadores, como Google, Microsoft, Amazon, Meta, OpenAI/Oracle, xAI, Alibaba y Tencent.

3. Informe técnico grupal

3.1. Tipos de mapas utilizados

Integrante	Tipo de mapa	Herramienta
Isaías Carte	Mapa coroplético mundial	Flourish
Benjamín Olguín	Mapa de símbolos proporcionales con codificación de color	Python / Plotly Express
Nicolás Gonzáles	Mapa de puntos	Datawrapper

Cuadro 1: Tipos de mapas y herramientas utilizadas por integrante.

3.2. Esquemática utilizada

La esquemática general del trabajo es de tipo **descriptiva y comparativa**, con una narrativa espacial progresiva. Primero, el mapa coroplético muestra la concentración territorial de modelos LLM notables por país. Luego, el mapa de Benjamín introduce una lectura bivariada, combinando tamaño de símbolo para la magnitud de producción y color para la proporción de modelos abiertos. Finalmente, el mapa de puntos desplaza el análisis desde la producción de modelos hacia la infraestructura física que permite entrenarlos y operarlos.

Esta secuencia permite conectar tres niveles del ecosistema LLM: concentración geográfica, apertura del ecosistema e infraestructura material de cómputo.

3.3. Colores usados y justificación

En el mapa de Isaías se utilizó una escala secuencial azul por cuartiles. Los tonos más oscuros representan países con mayor cantidad de modelos LLM notables y los tonos claros indican baja o nula presencia. La escala por cuartiles reduce el impacto visual de valores extremos como Estados Unidos y China.

En el mapa de Benjamín se utilizó tamaño de símbolo para representar la cantidad total de modelos y una escala divergente para el porcentaje de acceso abierto. Los tonos rojizos representan menor proporción de modelos abiertos, los tonos intermedios indican situaciones mixtas y los tonos azulados representan mayor proporción de apertura. Esta combinación permite distinguir simultáneamente países muy productivos y países con mayor o menor apertura, sin depender del área geográfica del territorio.

En el mapa de Nicolás se utilizaron colores categóricos para diferenciar operadores de centros de datos, mientras que el tamaño de los puntos representa la capacidad eléctrica en MW. Esta combinación permite leer simultáneamente ubicación, escala y actor responsable de la infraestructura.

3.4. Tipografía y coherencia visual

Para el informe se mantiene una estructura unificada, con títulos, subtítulos y leyendas consistentes. En la infografía final se recomienda utilizar una tipografía sans serif limpia, como Arial, Inter o similar, para favorecer la lectura rápida. La coherencia visual se refuerza manteniendo tamaños similares, paletas sobrias y evitando repetir información textual ya contenida en los mapas.

4. Síntesis para la infografía grupal

La infografía final debe integrar los tres mapas como una narrativa sobre la geografía global de los LLMs. La lectura sugerida es la siguiente:

1. **Dónde se producen los modelos:** el mapa coroplético muestra que el desarrollo de LLMs notables está altamente concentrado en pocos países.
2. **Qué tan abiertos son según el país:** el mapa de símbolos proporcionales muestra que la concentración de modelos no implica necesariamente una mayor apertura, y que existen estrategias nacionales distintas respecto a la publicación de pesos abiertos.
3. **Dónde se ubica la infraestructura que los sostiene:** el mapa de puntos muestra que los centros de datos y superclusters también se concentran en pocas regiones y operadores.

Como conclusión grupal, los tres mapas sugieren que el ecosistema de los LLMs no solo presenta concentración en el desarrollo de modelos, sino también diferencias importantes en la apertura

de ese ecosistema y en la infraestructura física necesaria para entrenarlos y operarlos. Esta concentración combina factores tecnológicos, económicos, energéticos y geopolíticos.

5. Fuentes de datos

Las fuentes utilizadas se organizaron según el mapa correspondiente:

- **Mapas de Isaías y Benjamín:** se utilizó la base *Notable AI Models* de Epoch AI, disponible en [Epoch AI – Notable AI Models](#). También se consideró la descarga directa del dataset en formato CSV: [notable_ai_models.csv](#).
- **Visualización de Isaías:** mapa coroplético publicado en Flourish, disponible en [visualización interactiva de Isaías](#).
- **Visualización de Nicolás:** mapa de puntos publicado en Datawrapper, disponible en [visualización interactiva de Nicolás](#).
- **Mapa de infraestructura física de cómputo:** el dataset fue construido a partir de fuentes especializadas y reportes públicos sobre centros de datos para IA, incluyendo [Epoch AI – Frontier Data Centers](#), [AI Data Center Index](#), [m-ric](#), [TechCrunch](#), [Sherwood News](#), [Neowin](#), [Rystad Energy](#) y [Blackridge Research](#).

6. Responsabilidad individual

Integrante	Aporte realizado
Isaías Carte Figueroa	Construcción del mapa coroplético mundial sobre concentración geográfica de modelos LLM notables. Preparación del dataset para Flourish, adaptación de nombres de países, inclusión de países con valor cero y redacción de descripción, objetivo y conclusión.
Nicolás Gonzáles	Construcción del mapa de puntos sobre infraestructura física de cómputo para IA. Recolección de datos sobre centros de datos, operadores, capacidad eléctrica, ubicación y estado de los proyectos, junto con su análisis y conclusión.
Benjamín Olguín Pozo	Construcción del mapa de símbolos proporcionales sobre modelos LLM por país y proporción de acceso abierto. Procesamiento del dataset de Epoch AI, filtrado de la variable <code>Open model weights?</code> , agregación por país, generación de visualización en Python/Plotly y redacción de justificación y conclusiones.

Cuadro 2: Distribución de responsabilidades individuales.